



SEMANA CINCO

SESIÓN UNO

Bloque C. Fuentes de datos

ÍNDICE

Subtemas:

- 3.1. Datos estructurados, semiestructurados y no estructurados
- 3.2. Fuentes de datos para Big Data



Bloque C: Fuentes de Datos


Saberes Declarativos:

- Datos estructurados, semiestructurados y no estructurados.
- Fuentes de datos para Big Data (texto, audio, video, etc.).

Evidencia y Ponderación:



Presentación audiovisual: Sobre una fuente de datos de Big Data, vinculada al Problema Prototípico.



Distribución estimada de tipos de datos en el mundo digital.

INTRODUCCIÓN

Saberes Declarativos: El estudiante debe conocer la clasificación de los datos en estructurados, semiestructurados y no estructurados, e identificar las diversas fuentes de Big Data (texto, audio, video, imágenes y datos de sensores).

Saberes Procedimentales: El estudiante deberá ser capaz de categorizar las fuentes de datos para un problema específico.

FUENTES DE DATOS



FUENTES DE DATOS

La clasificación de los datos es fundamental para elegir las herramientas y técnicas de análisis adecuadas.

FUENTES DE DATOS

El concepto de **Fuentes de Datos** es fundamental en la Ciencia de Datos, ya que constituye el origen y la materia prima de todo análisis y modelado.

En el contexto de negocios, entender las fuentes de datos no es solo un ejercicio técnico, sino una decisión estratégica que define la calidad de la información y el potencial de las soluciones propuestas.

FUENTES DE DATOS


Las fuentes de datos son los repositorios, sistemas, o canales desde donde se origina, recolecta o almacena la información que será procesada.

Para un científico de datos, identificar, evaluar y asegurar la calidad de estas fuentes es el primer paso crítico en el ciclo de vida de cualquier proyecto.

FUENTES DE DATOS

Datos Estructurados:

Son datos que tienen un esquema o modelo fijo. Se organizan en tablas con filas y columnas, como las bases de datos relacionales (MySQL, PostgreSQL). Son fáciles de analizar con herramientas tradicionales.



FUENTES DE DATOS

Bases de datos relacionales (MySQL, PostgreSQL).

Ejemplos

Hojas de cálculo (Excel).

Archivos CSV.



FUENTES DE DATOS

Datos Transaccionales (OLTP): Registros de ventas, inventario, pedidos de clientes.

Ejemplos:

Datos de *Data Warehouse* (OLAP): Datos agregados y consolidados para reportes empresariales.

Desafío:

Aunque son fáciles de gestionar, su rigidez dificulta la incorporación de datos nuevos o no anticipados.



PRÁCTICA DATOS ESTRUCTURADOS

FUENTES DE DATOS

Práctica de Laboratorio (Simulación de Búsqueda) y Análisis de Contenido.

Fuentes de datos (Datos Estructurados de su problema prototípico).

Objetivo de aprendizaje: Identificar datos estructurados esenciales para medir la sustentabilidad en un centro educativo y diseñar un esquema de base de datos relacional para capturarlos.

Esquema de Base de Datos Relacional (Diagrama) y **Reporte Descriptivo** de Fuentes.

Rúbrica de Evaluación (Ver detalle abajo).

Criterios: **Relevancia, Estructura y Normalización.**



FUENTES DE DATOS

Descripción de la actividad:

Apertura (10 min): El docente recuerda el Problema Prototípico (crear un modelo de sustentabilidad en un centro educativo). Se enfatiza que la medición de la sustentabilidad depende de datos precisos y estructurados. Se forman equipos de 3-4 estudiantes.

Desarrollo (40 min): Los equipos simulan ser analistas de datos encargados de diseñar la base de datos de un centro educativo.

Deben:

1. Identificar 5 indicadores clave de sustentabilidad (ej. consumo eléctrico, consumo de agua, reciclaje por tipo).
2. Para cada indicador, definir los campos de datos estructurados necesarios (ej. ID_medida, Fecha, Cantidad_kWh, Costo, Fuente).
3. Diseñar un esquema simple de Base de Datos Relacional (mínimo 3 tablas) que conecte estos indicadores.



FUENTES DE DATOS

Cierre (10 min): Cada equipo presenta su esquema de base de datos, justificando por qué eligieron esos campos y por qué la estructura relacional es la más adecuada para asegurar la Veracidad y la Consistencia de los datos de sustentabilidad.

Recursos necesarios: Software de diagramación (Draw.io, Lucidchart, Miro) o papel y lápiz.



RÚBRICA DE EVALUACIÓN: INVENTARIO ESTRUCTURADO DE RECURSOS

Criterio	Nivel de Desempeño	Ponderación
1. Relevancia y Coherencia de los Indicadores	30%	
Excelente (4)	Los 5 indicadores elegidos están directamente relacionados con el Problema Prototípico (sustentabilidad educativa) y son medibles con datos estructurados. El reporte justifica claramente su valor.	30%
Bueno (3)	Los indicadores son pertinentes, pero algunos podrían ser más específicos o su impacto en la sustentabilidad no está completamente justificado.	20%
Suficiente (2)	Los indicadores son vagos o solo tangencialmente relacionados con la sustentabilidad. Falta de justificación clara.	10%
Insuficiente (1)	Los indicadores elegidos no son medibles con datos estructurados o no tienen relación con el tema.	0%



RÚBRICA DE EVALUACIÓN: INVENTARIO ESTRUCTURADO DE RECURSOS

Criterio	Nivel de Desempeño	Ponderación
2. Estructura y Normalización de Datos	40%	
Excelente (4)	El esquema de la base de datos (mínimo 3 tablas) está bien definido y demuestra una comprensión de la normalización (ej. uso de claves primarias y foráneas). Los campos son lógicos y atómicos.	40%
Bueno (3)	La estructura es funcional, pero podría mejorarse la normalización. Las tablas y los campos cumplen con el objetivo principal de la actividad.	30%
Suficiente (2)	La estructura es plana o redundante (poca normalización). El esquema contiene inconsistencias en la definición de campos.	20%
Insuficiente (1)	No se presenta un esquema de base de datos o este es incorrecto.	0%



RÚBRICA DE EVALUACIÓN: INVENTARIO ESTRUCTURADO DE RECURSOS

Criterio	Nivel de Desempeño	Ponderación
3. Claridad y Presentación del Esquema	30%	
Excelente (4)	El diagrama es visualmente claro, ordenado y utiliza convenciones estándar (ej. para tipos de datos o relaciones). La presentación oral es concisa y justificativa.	30%
Bueno (3)	El diagrama es comprensible, aunque le falta pulcritud. La justificación oral es adecuada.	20%
Suficiente (2)	El diagrama es desordenado y las relaciones son difíciles de seguir. La presentación no es clara.	10%
Insuficiente (1)	El esquema es ilegible o no se presenta una justificación.	0%



SESIÓN DOS

FUENTES DE DATOS

Datos Semiestructurados:

Tienen una estructura, pero no una rígida. Se organizan con etiquetas o marcadores que definen los elementos, como los archivos JSON (JavaScript Object Notation) o XML.

FUENTES DE DATOS

Archivos JSON (JavaScript Object Notation).

Ejemplos:

Archivos XML (Extensible Markup Language).

FUENTES DE DATOS

Archivos JSON (JavaScript Object Notation): Muy común en APIs web.

Ejemplos:

Archivos XML (Extensible Markup Language): Históricamente utilizados para la transmisión de documentos.

Documentos NoSQL: Bases de datos orientadas a documentos (MongoDB).

Desafío:

Su flexibilidad puede complicar la uniformidad en la ingesta y el análisis si no se gestionan adecuadamente los *schemas* cambiantes.

SESIÓN TRES

FUENTES DE DATOS

Datos No Estructurados:

No tienen una estructura predefinida. Constituyen la mayor parte de los datos digitales generados hoy en día, como documentos de texto, correos electrónicos, imágenes, videos y archivos de audio.

FUENTES DE DATOS

Datos No Estructurados:

Requieren técnicas avanzadas de procesamiento, como el aprendizaje automático y el procesamiento del lenguaje natural.



FUENTES DE DATOS

Texto (documentos, correos electrónicos, tweets).

Ejemplos: Imágenes y videos.

Archivos de audio.



SEMANA SEIS


SESIÓN UNO

FUENTES DE DATOS PARA BIG DATA


La "variedad" del Big Data se refiere a la diversidad de estas fuentes. La capacidad de analizar datos de múltiples orígenes es una de las principales ventajas de la ciencia de datos.




FUENTES DE DATOS PARA BIG DATA



El Big Data se nutre de una gran diversidad de fuentes.



La habilidad del científico de datos es saber dónde buscar la información relevante.



Las fuentes pueden ser internas (datos de la empresa) o externas (datos públicos).

FUENTES DE DATOS PARA BIG DATA

Texto: Fuentes como las redes sociales, los correos electrónicos, los foros en línea y las reseñas de clientes. Técnicas de análisis (PLN).



FUENTES DE DATOS PA

Profundización en texto:

Análisis de sentimientos en una muestra de tweets.

Código de ejemplo



FUENTES DE DATOS PARA BIG DATA

Audio: Grabaciones de llamadas de centros de atención al cliente, podcast y archivos de música y técnicas de análisis.



FUENTES DE DATOS PARA BIG DATA

El reconocimiento de voz y el análisis de la emoción son técnicas clave.

```
import librosa
y, sr=librosa.load("audio_file.wav")
melspectrogram = librosa.feature.
    y=y, sr=sr
import numpy as np
log_mel = np.log(melspectrogram)
```



PYTHON

FUENTES DE DATOS PA

Profundización en audio: Análisis de transcripciones.

```
import librosa
y, sr=librosa.load("audio_file.wav")
melspectrogram = librosa.feature.
    y=y, sr=sr
import numpy as np
log_mel = np.log(melspectrogram)
```



PYTHON

FUENTES DE DATOS PARA BIG DATA

Tabla de Características Acústicas Clave para SER

Característica Acústica	Propósito Funcional	Relevancia para la Ira	Librería Python
MFCC (Estático, 13 coef.)	Captura la envolvente espectral y el timbre (forma del tracto vocal)	Alteraciones consistentes en la resonancia vocal por tensión muscular.	<code>librosa.feature.mfcc</code>
MFCC Delta (Dinámico, 13 coef.)	Mide la velocidad de cambio de las características espectrales.	Rapidez de las transiciones de tono y ataque vocal característicos de la explosividad.	<code>librosa.feature.delta</code>
MFCC Delta-Delta (Aceleración, 13 coef.)	Mide la aceleración de los cambios espectrales.	Inestabilidad vocal y alta excitación (frecuente en ira intensa).	<code>librosa.feature.delta</code>
Root Mean Square Energy (RMSE)	Medida del volumen o intensidad (loudness).	Indicador primario de alta excitación y gritos.	<code>librosa.feature.rms</code>


SESIÓN DOS

FUENTES DE DATOS PARA BIG DATA

Video e Imágenes: Contenido de YouTube, fotos en redes sociales, imágenes médicas y feeds de cámaras de seguridad.

Fuentes de Big Data

7




FUENTES DE DATOS PARA BIG DATA

La visión por computadora es la técnica principal para extraer información.

Fuentes de Big Data

7




FUENTES DE DATOS PARA BIG DATA

Profundización en imágenes: Detección de objetos.

Fuentes de Big Data

7




DEFINICIÓN DE PRODUCTO DE DATOS FUENTES DE DATOS PARA BIG DATA

Datos de Sensores: Información generada por el Internet de las Cosas (IoT), como los sensores de temperatura, humedad y GPS en vehículos.



a)



b)



c)




d)



e)



f)



g)




h)

DEFINICIÓN DE PRODUCTO DE DATOS FUENTES DE DATOS PARA BIG DATA

Estos datos suelen ser en tiempo real y son cruciales para el monitoreo y el mantenimiento predictivo.



a)




b)



c)




d)



e)



f)



g)



h)

RETOS AL TRABAJAR CON BIG DATA


Volumen: La cantidad de datos es abrumadora.

Velocidad: Los datos se generan y cambian rápidamente.

Variedad: La diversidad de formatos dificulta el procesamiento.

Veracidad: La calidad de los datos puede ser dudosa.

Valor: El objetivo final es convertir datos en valor tangible.




LA IMPORTANCIA DE LA CATEGORIZACIÓN

La categorización de las fuentes de datos es un paso crítico.

Permite elegir la herramienta y el método de análisis correctos.

Facilita la planificación de un proyecto de Ciencia de Datos.



SESIÓN TRES

CONCLUSIÓN DEL BLOQUE C

Resumen: Fuentes de datos

- Los datos se clasifican en estructurados, semiestructurados y no estructurados.
 - El Big Data se nutre de una gran variedad de fuentes.
 - Es fundamental identificar y categorizar las fuentes para un análisis efectivo.

The background features a repeating pattern of light gray speech bubbles, each containing a dark teal question mark. The bubbles are arranged in a staggered, overlapping manner against a dark teal background. On the far left, there is a vertical red bar and a white dotted line.

PREGUNTAS Y RESPUESTAS

REFERENCIAS

Aguilar, L. J. (2020). Big Data Análisis de grandes volúmenes de datos en organizaciones. Editorial Alfaomega.

Kelleher, J. D., & Tierney, B. (2021). Ciencia de datos. Editorial MIT Press Conocimientos Esenciales.

O'Neil, C., & Schutt, R. (2013). Doing Data Science. Editorial O'reilly Media, Inc.



SIGUIENTE BLOQUE:

Procesos de Ciencia de Datos

Este bloque detalla el ciclo de vida de un proyecto de ciencia de datos, desde la formulación del problema hasta la entrega de los resultados.

Actividad práctica final para evaluar el bloque C:

Presentación Audiovisual de una Fuente de Datos

- o Ponderación: 10% de la calificación final del bloque.
- o Descripción: De manera individual, los estudiantes crearán una presentación audiovisual (video corto) explicando una fuente de datos de Big Data (texto, audio, video o sensores) y cómo se relaciona con el problema prototípico.
- o Duración: 60 minutos.
- o Herramientas: Clipchamp, Google Slides (con grabación de voz), cualquier editor de video simple.

Actividad práctica final para evaluar el bloque C:

Presentación Audiovisual de una Fuente de Datos

Desarrollo:

1. 10 min: Selección de la fuente de datos a explorar (ej. datos de redes sociales, cámaras de seguridad, etc.).
2. 30 min: Preparación del guion y la grabación del video. Se deben usar imágenes, íconos y voz para explicar la fuente de datos.
3. 15 min: Edición del video para asegurar que la duración no exceda los 5 minutos y que la información sea clara.
4. 5 min: Subida del video a una plataforma compartida para su revisión.



<https://www.rcastellanos.cdmx.gob.mx/>